

Graph scoring

Tasas más justas para quienes no tienen historial crediticio

El problema

En Argentina, millones de personas y pymes son **thin-file**: sin historial crediticio formal, quedan fuera del crédito o pagan tasas de castigo. El scoring tradicional solo sabe puntuar a quien ya tiene historial — un círculo que excluye precisamente a quien más necesita entrar.

La solución

red_scoring estima el riesgo a partir de la **posición de cada CUIT en una red**, no solo de su historial individual. Construimos un grafo de **~1.300 CUITs y 33.000 aristas**, donde dos nodos se conectan si comparten entidad financiera y tienen escala económica similar — todo con **datos 100% públicos** (Central de Deudores del BCRA, padrón AFIP).

BCRA + AFIP → grafo de CUITs → comunidades → features de red → score 0–1000

Por qué es creíble: validación honesta

La trampa típica de estos modelos es la **fuga de target** — usar como predictor el mismo dato que define la etiqueta, lo que infla el AUC a ~1.0 y no prueba nada. La detectamos y la eliminamos: **ninguna feature de historial entra al modelo**. Por eso estos números son reales.

Modelo	Qué "ve" el modelo	AUC-ROC
Baseline	escala + entidad	0.76
+ Red	escala + entidad + red	0.76
Solo red	solo la posición en la red	0.67

Lo relevante para thin-file: usando únicamente la posición en la red —sin historial ni escala propia — el modelo ordena el riesgo con **AUC 0.67**, muy por encima del azar (0.50). Es exactamente la población que el sistema tradicional no puede puntuar.

Hallazgo accionable: detectando comunidades por escala, la comunidad de **mayor escala económica es la más morosa** (~25 % en mora vs. ~7 % en las más chicas) — contraintuitivo y directamente útil para política de tasas.

No es un notebook: es un producto

Reproducible	make setup && make all corre el pipeline end-to-end
Empaquetado	paquete instalable src/red_scoring/, un comando por etapa
Sin exponer PII	datos reales fuera de git + sample sintético para reproducir
Testeado	pytest corre el pipeline completo; CI verde en cada push
Stack	Python 3.11 · NetworkX · scikit-learn · pandas

Roadmap

La red de monto es la **primera capa de aristas**. El próximo salto es sumar vínculos que conecten también a thin-files puros —co-residencia (padrón electoral), persona-empresa, geografía— donde la hipótesis de "buenos vecinos, mejor tasa" tiene más para dar. La infraestructura para probarlo ya está construida.

Fuentes de datos

Todo el pipeline se alimenta de **datos públicos**, sin scraping ni datos privados:

- **BCRA — Central de Deudores** (situación crediticia por CUIT, ground truth): API REST pública <https://api.bcra.gob.ar/CentralDeDeudores/v1.0/Deudas/{cuit}>
- **BCRA — Estadísticas** (entidades financieras y tasas): <https://api.bcra.gob.ar/estadisticas/v2.0/> — catálogo de APIs en bcra.gob.ar
- **AFIP — Padrón de contribuyentes** (categoría, actividad y estado por CUIT): descarga pública de padrones AFIP

